

# Universidade Federal de Uberlândia

Autor: Henrique Santos de Lima

Docente: Prof. Dr. Keiji Yamanaka

Outubro

2023

Universidade Federal de Uberlândia

## **Trabalho 05 de Inteligencia Artificial**

Rede Neural Adaline e a Regressão Linear

Autor : Henrique Santos de Lima

Outubro

2023

**Conteúdo**

<b>1</b>	<b>Problema</b>	<b>2</b>
<b>2</b>	<b>A rede neural Adaline</b>	<b>2</b>
<b>3</b>	<b>Regressão linear</b>	<b>3</b>
<b>4</b>	<b>Métricas</b>	<b>4</b>
<b>5</b>	<b>Coefficiente de Pearson</b>	<b>4</b>
<b>6</b>	<b>Solução</b>	<b>5</b>
6.1	Gráfico Com a regressão linear do conjunto de dados . . . . .	5
<b>7</b>	<b>Conclusão</b>	<b>7</b>

# 1 Problema

Utilize a base de observações para:

- Treinar uma Adaline com esta base de observações
- Traçar a linha de regressão linear
- Comparar os resultados de regressão com os obtidos utilizando as equações de a e b
- Encontrar o coeficiente de correlação de Pearson e o coeficiente de determinação.

# 2 A rede neural Adaline

A rede chamada de Adaline permitiu a utilização de valores reais nas entradas e até mesmo nas saídas dos neurônios, isso foi possível ao utilizar a função de ativação linear e o gradiente descendente.

Para calcular os valores que serão corrigidos nos pesos, primeiro calcula-se o erro que as saídas estão gerando em relação ao objetivo, como mostra a Equação 1.

$$E = \frac{(y - t)^2}{2} \quad (1)$$

A variação do peso anterior para o novo peso é proporcional ao gradiente do erro, como mostra a equação 2.

$$dw \propto -\frac{\partial E}{\partial w} = -\frac{\partial E}{\partial y} * \frac{\partial y}{\partial w} = -\frac{\partial E}{\partial y} * \frac{\partial (x * w + b)}{\partial w} = (t - y) * x \quad (2)$$

Dessa forma é possível fazer pequenos ajustes nos pesos.

---

**Algorithm 1** Algoritmo de Treinamento do Perceptron

---

```
1: Inicializar todos os pesos:  $w_i = 0$  para  $i = 1$  a  $n$ ,  $b = 0$ .
2: Inicializar taxa de aprendizagem  $\alpha$  ( $0 < \alpha \leq 1$ ).
3: Inicializar condição de parada.
4: while condição de parada for falsa do
5:   for cada par (vetor de entrada  $\mathbf{s}$ , saída  $t$ ) do
6:      $\mathbf{x} = \mathbf{s}$  {Para  $i = 1$  a  $n$ }
7:     Calcular a saída  $y_{\text{liq}}$ :
8:      $y_{\text{liq}} = \sum_{i=1}^n w_i x_i + b$ 
9:     for cada peso  $w_{ij}$  do
10:      Atualizar o peso:  $w_{ij} = w_{ij} + \alpha * (t_j - y_j) * x_i$ 
11:    end for
12:    Atualizar o viés:  $b = b + \alpha * (t_j - y_j)$ 
13:  end for
14:  Testar condição de parada: Verificar se não houve mudança de pesos.
15: end while
```

---

### 3 Regressão linear

A regressão linear é uma técnica que permite encontrar uma reta com o menor erro quadrático médio em relação a um conjunto de pontos de um espaço amostral.

A equação linear é da forma

$$f(x) = b * x + a \quad (3)$$

Em que:

$$b = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2}$$

$$a = \bar{y} - \bar{x} \cdot b$$

$\bar{y}$  é a média dos valores de  $y$  (a variável dependente). (4)

$\bar{x}$  é a média dos valores de  $x$  (a variável independente).

$x_i$  e  $y_i$  são os valores individuais de  $x$  e  $y$ .

$\sum$  representa a soma dos valores em um conjunto de dados.

## 4 Métricas

Para avaliar o erro entre dois conjuntos, pode-se utilizar algumas métricas tais como a tabela abaixo mostra.

Métrica	Equações
Mean Squared Error (MSE)	$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$
Root Mean Squared Error (RMSE)	$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$
Mean Absolute Error (MAE)	$MAE = \frac{1}{n} \sum_{i=1}^n  y_i - \hat{y}_i $
R Square ( $R^2$ )	$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$

Tabela 1: Métricas utilizadas para medir o erro

## 5 Coeficiente de Pearson

O coeficiente de Pearson, ou coeficiente de correlação de Pearson, é uma medida estatística que quantifica a relação linear entre duas variáveis. Ele varia de -1 a 1, onde -1 indica uma correlação negativa perfeita, 1 indica uma correlação positiva perfeita e 0 representa a ausência de correlação linear. Pode ser calculado a partir da Equação 5

$$r = \frac{n \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{n \sum_{i=1}^n (x_i - \bar{x})^2} \cdot \sqrt{n \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (5)$$

O coeficiente de determinação ( $R^2$ ) mede o grau em que a variabilidade dos dados é explicada pelo modelo de regressão.  $R^2$  é o quadrado do coeficiente de Pearson  $r$ , variando de 0 a 1. Quanto mais próximo de 1, mais bem o modelo se ajusta aos dados. Quando  $R^2 = 0$  indica que o modelo não explica a variabilidade, enquanto  $R^2 = 1$  significa que o modelo explica toda a variabilidade. Portanto,  $R^2$  é uma medida da qualidade do ajuste de um modelo de regressão aos dados.

## 6 Solução

### 6.1 Gráfico Com a regressão linear do conjunto de dados

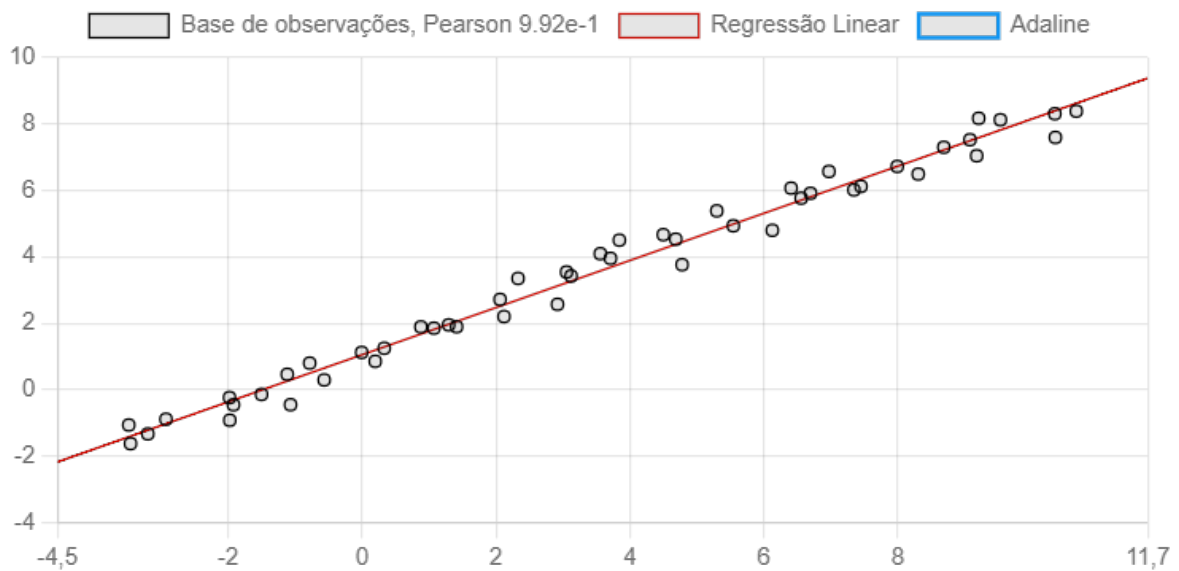


Figura 1: Regressão linear e pontos dos dados

A figura 1 mostra a reta encontrada pela regressão linear, essa é a reta com o menor erro médio em relação a todos os pontos.

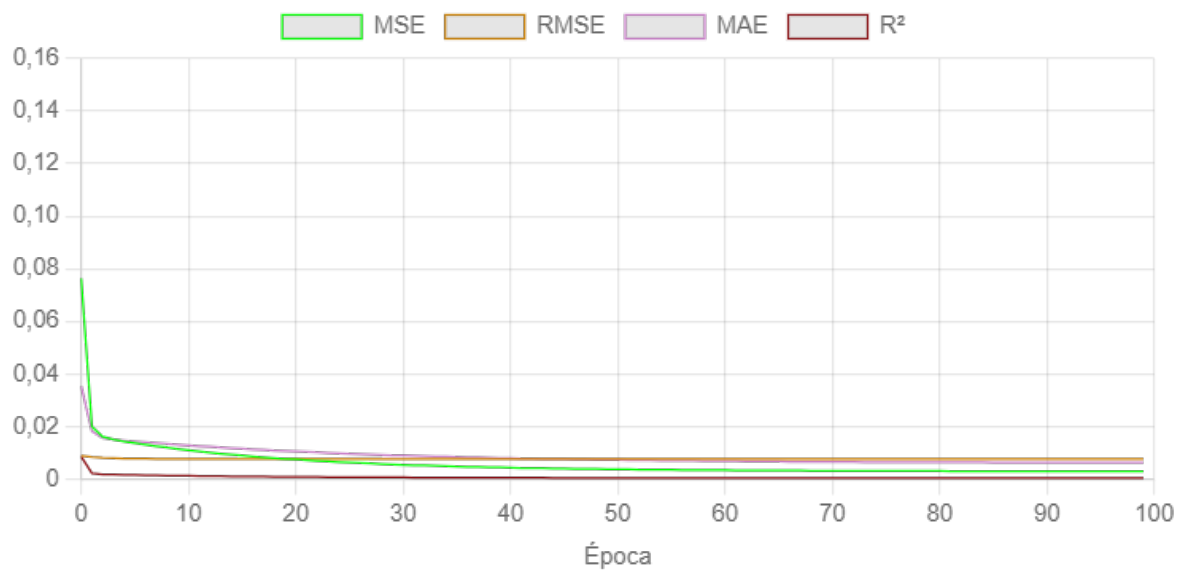


Figura 2: Métricas de erros calculada durante o treinamento

A figura 2 mostra as curvas de erros diminuindo conforme a rede neural vai treinando.




Figura 3: Reta da regressão linear e reta da rede neural (primeira época)

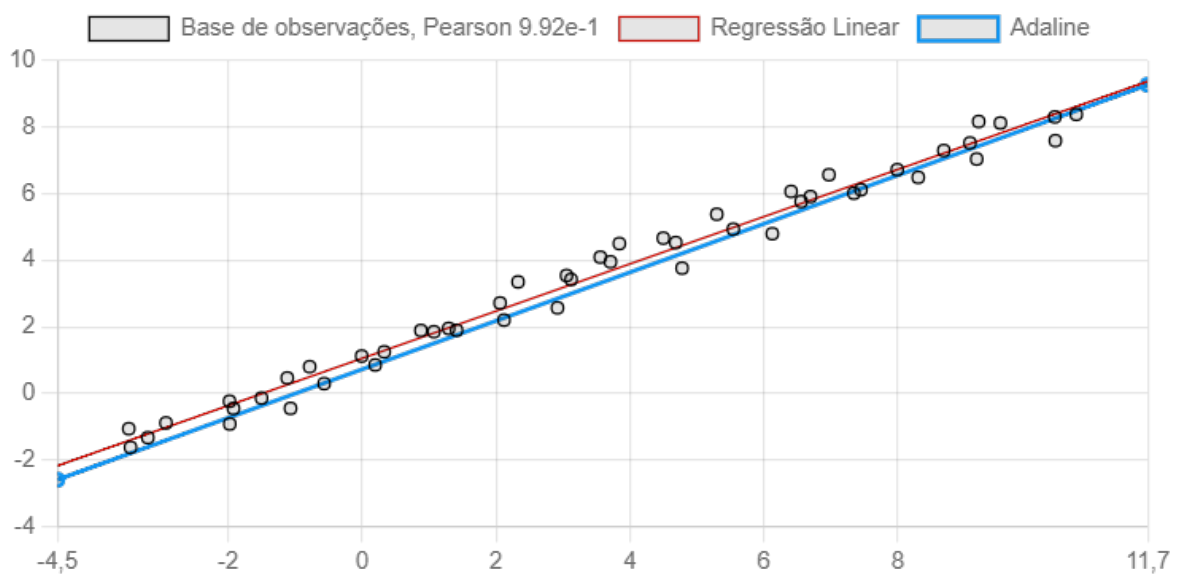


Figura 4: Reta da regressão linear e reta da rede neural (segunda época)



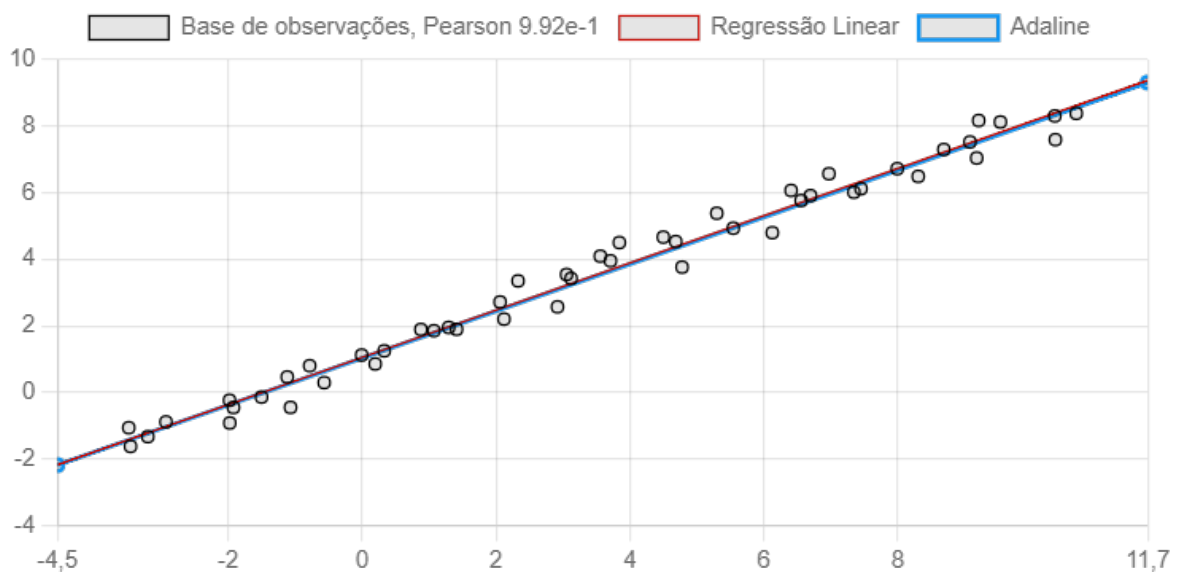


Figura 5: Reta da regressão linear e reta da rede neural (última época)

As Figuras 3, 4 e 5 mostram a reta obtida pela rede neural se aproximando da reta obtida pela regressão linear.

Coeficiente de Pearson	Coeficiente de determinação
0.9920	0.9840

Tabela 2: Coeficientes de Pearson e Coeficiente de determinação

Os coeficiente são apresentados na tabela 2, e indicam que os dados se ajustam bem uma regressão linear.

## 7 Conclusão

Este trabalho permite visualizar como o algoritmo da rede neural Adaline se assemelha da regressão Linear, onde a reta obtida pela Adaline tende a reta encontrada pela regressão Linear.

Apesar de existirem outras métricas de erro, no algoritmo Adaline é utilizado o MSE devido a facilidade de calcular sua derivada, utilizado para correção dos pesos.

Os coeficientes de Pearson e de determinação são uteis para identificar se a rede neural Adaline será capaz de aprender e encontrar uma solução que atenda o problema.

## Referências

- 1 DUDA, R. O.; HART, P. E.; STORK, D. G. *Pattern Classification*. 2nd edition. ed. Nashville, TN: Wiley-Interscience, 2000. 688 p. ISBN 0471056693.
- 2 HAYKIN, S. *Redes Neurais - 2ª edição*. 2ª edição. ed. [S.l.]: Bookman, 2000. 898 p. ISBN 8573077182.
- 3 HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. [S.l.]: Springer, 2009.